LAPORAN TUGAS BESAR FASE 1

IF4071 Pemrosesan Ucapan

Pengumpulan Korpus Suara Bahasa Sunda



Disusun oleh Kelompok 6

Nadhif Radityo Nugroho (13523045)

Aldoy Fauzan Avanza (18223113)

M Rabbani K A (18223130)

Sekolah Teknik Elektro dan Informatika

Institut Teknologi Bandung

Semester I Tahun Akademik 2026/2027

Repository GitHub:

https://github.com/aldoyfa/sundanese-corpus

1. Pendahuluan

Laporan ini menjelaskan proses pembuatan korpus suara bahasa Sunda untuk Tugas Besar Fase 1 mata kuliah IF4071 Pemrosesan Ucapan. Korpus ini akan dipakai untuk membangun dan menguji sistem pengenal ucapan (ASR) bahasa Sunda pada Fase 2.

Rekaman berupa monolog. Setiap penutur bercerita tentang dirinya pada beberapa topik sehari-hari, dengan satu rekaman untuk setiap topik. Penuturnya berasal dari berbagai daerah dan kebiasaan mereka memakai bahasa Sunda berbeda-beda, sehingga korpus ini memuat variasi cara berbicara yang cukup beragam.

Seluruh data korpus tersimpan di repository GitHub kelompok pada alamat https://github.com/aldoyfa/sundanese-corpus.

2. Desain Korpus

Korpus dirancang dengan ketentuan berikut.

- Jumlah penutur ada 10 orang, terdiri dari 5 laki-laki (S01–S05) dan 5 perempuan (S06–S10).
- Tersedia 7 topik, yaitu perkenalan, kegiatan sehari-hari, keluarga, makanan, pekerjaan atau pendidikan, perjalanan, dan budaya. Setiap penutur membahas minimal 4 topik.
- Durasi ditargetkan 10–15 menit per penutur. Hasilnya 9,8–14,9 menit dengan total 117,4 menit dalam 51 file.
- Audio berformat WAV 16 kHz, 16-bit, mono, dan direkam di dalam ruangan yang relatif tenang.
- Nama file memakai pola SXX_TYY_NNN.wav, yaitu kode penutur, kode topik, dan nomor urut.
- Setiap file punya metadata, dan setiap rekaman dibagi menjadi segmen untuk anotasi.

3. Penutur

Tabel berikut berisi daftar penutur. Nama asli tidak disimpan dan usia dicatat dalam rentang.

Penutur	Gender	Usia	Asal	Durasi (menit)
S01	L	18–22	Malang, Jawa Timur	12,8
S02	L	18–22	Blitar, Jawa Timur	13,5
S03	L	18–22	Malang, Jawa Timur	10,1
S04	L	18–22	Jakarta	11,1
S05	L	18–22	Buah Batu, Bandung	14,9
S06	P	18–22	Malang, Jawa Timur	12,9
S07	P	18–22	Malang, Jawa Timur	9,8
S08	P	18–22	Bandung	11,6
S09	P	18–22	Bekasi, Jawa Barat	10,7
S10	P	50–59	Karawang, Jawa Barat	10,2

Sembilan penutur berusia 18–22 tahun dan satu penutur (S10) berusia 50–59 tahun. Daerah asal mereka beragam, yaitu Malang, Blitar, Jakarta, Bekasi, Karawang, dan Bandung. Karena itu, kebiasaan

memakai bahasa Sunda sehari-hari juga berbeda di antara para penutur.

4. Proses Perekaman

Rekaman dibuat memakai HP di ruangan yang tenang. Untuk S01–S04 dan S06–S08, setiap sesi direkam dengan dua HP sekaligus, lalu dipilih rekaman yang lebih bersih (SNR lebih tinggi).

Rekaman asli berformat AAC (.m4a) 48 kHz dan dikonversi satu kali dengan ffmpeg ke WAV 16 kHz, 16-bit, mono, tanpa pengurangan noise maupun normalisasi. Rekaman S05 berformat WAV 48 kHz dan diubah dengan cara yang sama, sedangkan rekaman S10 sudah berformat 16 kHz.

Sesi yang panjang dipotong per topik di titik paling hening di sekitar pergantian topik. Bagian S01 yang melebihi target durasi dan obrolan penutup di akhir rekaman tidak dipakai.

5. Quality Control

Setiap file diperiksa secara otomatis untuk format, durasi, clipping, level suara, dan estimasi SNR. Label diberikan berdasarkan kriteria berikut.

- Good, jika tidak ada clipping dan SNR minimal 20 dB.
- Acceptable, jika ada clipping ringan, SNR 10–20 dB, atau suara terlalu pelan.
- Reject, jika clipping berat, SNR di bawah 10 dB, atau format tidak sesuai.

Hasilnya, ke-51 file berlabel Good dengan SNR 20,6–40,4 dB (median 37,9 dB) dan tanpa clipping. SNR terendah ada pada rekaman S09 (20,6–22,2 dB) yang direkam dengan bitrate lebih rendah. Karena tidak ada file Reject, tidak ada rekaman yang perlu diulang. Hasil lengkapnya ada di berkas documentation/qc_report.csv.

6. Anotasi dan Validasi

Setiap file dibagi menjadi segmen sekitar 15 detik di titik jeda. Hasilnya 480 segmen dengan sekitar 10.700 kata.

Transkripsi dibuat dengan model ASR Whisper-medium yang sudah dilatih untuk bahasa Sunda. Untuk S09 dan S10, hasilnya dirapikan lagi secara semiotomatis sehingga lebih bersih. Untuk S01–S08, transkrip masih berupa hasil ASR dengan nama yang sudah disamarkan. Transkrip ini belum dikoreksi penuh sehingga masih ada kata yang salah dengar.

Label yang dipakai adalah [NAME] untuk nama orang yang disamarkan (20 segmen), [laugh] untuk tawa (3 segmen), dan [unclear] untuk kata yang tidak bisa dipulihkan (3 segmen). Label noise, overlap, dan alih kode sudah disiapkan tetapi tidak ditemukan di rekaman. Semua rekaman berupa monolog, jadi tidak ada ucapan yang tumpang tindih.

Format anotasi dicek secara otomatis, mencakup tag, waktu mulai dan selesai, serta kesesuaiannya dengan durasi audio.

7. Hasil

Korpus akhir berisi 51 file dengan total 117,4 menit dan 480 segmen. Durasi tiap penutur berkisar 9,8–14,9 menit, dan hanya S07 yang sedikit di bawah target 10 menit. Durasi per topik dapat dilihat pada tabel berikut.

Topik	Durasi (menit)
Perkenalan	22,6
Kegiatan sehari-hari	26,6
Keluarga	5,9
Makanan	18,8

Pekerjaan atau pendidikan	15,8
Perjalanan	9,8
Budaya	17,9

8. Etika

Semua penutur menandatangani formulir persetujuan (informed consent) sebelum direkam, termasuk persetujuan agar datanya disimpan di repositori GitHub yang bisa diakses publik. Penutur hanya dikenali lewat kode, nama orang di transkrip diganti dengan [NAME], dan nama asli serta kontak tidak disimpan. Daerah asal dicatat sampai tingkat kota saja. Data dilisensikan CC BY-NC 4.0 sehingga hanya boleh dipakai untuk pendidikan dan penelitian nonkomersial.

9. Kendala

- Transkrip S01–S08 masih hasil ASR yang belum dikoreksi penuh sehingga akurasinya terbatas.
- Rekaman S09 memakai bitrate yang lebih rendah dari penutur lain sehingga SNR-nya paling rendah, walaupun masih lolos kriteria Good.
- Sesi S01 terlalu panjang sehingga dipotong agar sesuai target durasi.
- Cakupan topik belum merata. Topik keluarga dan perjalanan paling sedikit.
- Segmen berupa jendela sekitar 15 detik, belum per kalimat, dan batas potongan topik bisa meleset beberapa detik.

10. Kontribusi Anggota

Pembagian kerja anggota kelompok dapat dilihat pada tabel berikut.

Nama	NIM	Kontribusi
Nadhif Radityo Nugroho	13523045	Konversi audio dan quality control
Aldoy Fauzan Avanza	18223113	Koordinator kelompok dan pengelolaan metadata
M Rabbani K A	18223130	Anotasi dan pengelolaan repository GitHub