LAPORAN TUGAS BESAR FASE 1

IF4071 Pemrosesan Ucapan

Pengumpulan Korpus Suara Bahasa Sunda



Disusun oleh Kelompok 6

Nadhif Radityo Nugroho (13523045)

Aldoy Fauzan Avanza (18223113)

M Rabbani K A (18223130)

Sekolah Teknik Elektro dan Informatika

Institut Teknologi Bandung

Semester I Tahun Akademik 2026/2027

Repositori GitHub: https://github.com/aldoyfa/sundanese-corpus

1. Pendahuluan

Laporan ini menjelaskan proses pembuatan korpus suara bahasa Sunda untuk Tugas Besar Fase 1 mata kuliah IF4071 Pemrosesan Ucapan. Korpus ini akan dipakai untuk membangun dan menguji sistem pengenal ucapan (*automatic speech recognition*, ASR) bahasa Sunda pada Fase 2.

Rekaman berupa monolog. Setiap penutur bercerita tentang dirinya pada beberapa topik sehari-hari, dengan satu rekaman untuk setiap topik. Penuturnya berasal dari berbagai daerah dan kebiasaan mereka memakai bahasa Sunda berbeda-beda, sehingga korpus ini memuat variasi cara berbicara yang cukup beragam.

Seluruh data korpus tersimpan di repositori GitHub kelompok pada alamat https://github.com/aldoyfa/sundanese-corpus.

2. Desain Korpus

Tabel 1 merangkum rancangan korpus yang dipakai.

Tabel 1. Rancangan korpus

Aspek	**Ketentuan**
Penutur	10 orang, terdiri dari 5 laki-laki (S01–S05) dan 5 perempuan (S06–S10)
Jenis ucapan	Monolog, satu rekaman untuk setiap topik
Topik	7 topik tersedia (T01–T07), minimal 4 topik per penutur. Rinciannya ada pada Tabel 8.
Durasi	Target 10–15 menit per penutur. Hasilnya 9,8–14,9 menit, total 117,4 menit dalam 51 file.

Format audio	WAV 16 kHz, 16-bit, *mono*
Lingkungan	Dalam ruangan yang relatif tenang
Nama file	`SXX_TYY_NNN.wav` (kode penutur, kode topik, nomor urut)
Metadata dan anotasi	`metadata/metadata.csv` per file dan `annotation/annotation.csv` per segmen

3. Penutur

Tabel 2 berisi daftar penutur. Nama asli tidak disimpan dan usia dicatat dalam rentang.

Tabel 2. Daftar penutur

Penutur	Gender	Usia	Asal	Durasi (menit)
S01	L	18–22	Malang, Jawa Timur	12,8
S02	L	18–22	Blitar, Jawa Timur	13,5
S03	L	18–22	Malang, Jawa Timur	10,1
S04	L	18–22	Jakarta	11,1
S05	L	18–22	Buah Batu, Bandung	14,9
S06	P	18–22	Malang, Jawa Timur	12,9
S07	P	18–22	Malang,	9,8

			Jawa Timur	
S08	P	18–22	Bandung	11,6
S09	P	18–22	Bekasi, Jawa Barat	10,7
S10	P	50–59	Karawang, Jawa Barat	10,2

- Sembilan penutur berusia 18–22 tahun dan satu penutur (S10) berusia 50–59 tahun.
- Daerah asal beragam, yaitu Malang, Blitar, Jakarta, Bekasi, Karawang, dan Bandung.
- Karena itu, kebiasaan memakai bahasa Sunda sehari-hari berbeda di antara para penutur.

4. Proses Perekaman

Rekaman diproses dengan langkah berikut.

1. Merekam memakai HP di ruangan yang tenang. Untuk S01–S04 dan S06–S08, setiap sesi direkam dengan dua HP sekaligus, lalu dipilih rekaman yang lebih bersih (SNR lebih tinggi).
2. Mengonversi rekaman asli ke WAV 16 kHz, 16-bit, *mono* dengan `ffmpeg`. Konversi dilakukan satu kali, tanpa pengurangan *noise* maupun normalisasi.
3. Memotong sesi yang panjang per topik di titik paling hening di sekitar pergantian topik.
4. Membuang bagian S01 yang melebihi target durasi dan obrolan penutup di akhir rekaman.

Perintah konversi yang dipakai adalah sebagai berikut.

```
ffmpeg -i input.m4a -ac 1 -ar 16000 -c:a pcm_s16le -map_metadata -1
  output.wav
```

Format rekaman asli berbeda-beda dan ditangani seperti pada Tabel 3.

Tabel 3. Format rekaman asli dan penanganannya

Penutur	Format asli	Penanganan
S01–S04, S06–S09	AAC (`.m4a`) 48 kHz	Dikonversi dengan `ffmpeg`
S05	WAV 48 kHz	Diubah ke 16 kHz dengan cara yang sama
S10	WAV 16 kHz	Dipakai langsung

5. *Quality Control*

Setiap file diperiksa secara otomatis untuk format, durasi, *clipping*, level suara, dan estimasi SNR. Label diberikan sesuai kriteria pada Tabel 4.

Tabel 4. Kriteria label kualitas dan hasilnya

Label	Kriteria	Jumlah file
Good	Tidak ada *clipping* dan SNR minimal 20 dB	51
Acceptable	*Clipping* ringan, SNR 10–20 dB, atau suara terlalu pelan	0
Reject	*Clipping* berat, SNR di bawah 10 dB, atau format tidak sesuai	0

- SNR seluruh file berkisar 20,6–40,4 dB dengan median 37,9 dB, tanpa *clipping*.

- SNR terendah ada pada rekaman S09 (20,6–22,2 dB) yang direkam dengan *bitrate* lebih rendah.
- Tidak ada file *Reject*, sehingga tidak ada rekaman yang perlu diulang.
- Hasil lengkap per file ada di `documentation/qc_report.csv`.

6. Anotasi dan Validasi

Anotasi dikerjakan dengan alur berikut.

1. Membagi setiap file menjadi segmen 3 sampai 15 detik di titik jeda. Hasilnya 714 segmen dengan sekitar 10.800 kata.
2. Membuat transkripsi dengan model ASR Whisper-medium yang sudah dilatih untuk bahasa Sunda.
3. Menyamarkan nama orang dengan label `[NAME]`.
4. Memeriksa format anotasi secara otomatis, mencakup label, waktu mulai dan selesai, serta kesesuaiannya dengan durasi audio.

Sumber transkrip berbeda untuk tiap kelompok penutur, seperti pada Tabel 5.

Tabel 5. Sumber transkrip

Penutur	Sumber transkrip	Kondisi
S09, S10	Hasil ASR yang dirapikan secara semiotomatis	Cukup bersih
S01–S08	Hasil ASR dengan nama yang sudah disamarkan	Belum dikoreksi penuh, masih ada kata yang salah dengar

Label yang dipakai pada transkrip beserta jumlah segmennya dapat dilihat pada Tabel 6.

Tabel 6. Label pada transkrip

Label	Arti	Jumlah segmen
`[NAME]`	Nama orang yang disamarkan	9
`[laugh]`	Tawa	0
`[unclear]`	Kata yang tidak bisa dipulihkan	4
`[noise]`, `[cough]`, `[overlap]`, `[pause]`	Suara latar, batuk, ucapan tumpang tindih, dan jeda panjang	0
`<id>…</id>`, `<en>…</en>`	Alih kode ke bahasa Indonesia atau Inggris	0

Label dengan jumlah 0 sudah disiapkan tetapi tidak ditemukan di rekaman. Semua rekaman berupa monolog, sehingga tidak ada ucapan yang tumpang tindih.

Hasil anotasi disimpan di `annotation/annotation.csv`. Kolom utamanya dijelaskan pada Tabel 7.

Tabel 7. Kolom utama pada `annotation.csv`

Kolom	Isi
`start`, `end`	Waktu mulai dan selesai segmen (detik)
`transcript`	Transkrip dengan label
`transcript_norm`	Transkrip huruf kecil tanpa label dan tanda baca, siap dipakai melatih ASR
`events`	Daftar label kejadian khusus pada

	segmen
`speaker`, `topic`, `language_dialect`	Penutur, topik, dan bahasa pada segmen

7. Hasil

- Total 51 file dengan durasi 117,4 menit dan 714 segmen.
- Durasi tiap penutur 9,8–14,9 menit. Hanya S07 yang sedikit di bawah target 10 menit.
- Durasi per topik dapat dilihat pada Tabel 8.

Tabel 8. Durasi per topik

Kode	Topik	Durasi (menit)
T01	Perkenalan	22,6
T02	Kegiatan sehari-hari	26,6
T03	Keluarga	5,9
T04	Makanan	18,8
T05	Pekerjaan atau pendidikan	15,8
T06	Perjalanan	9,8
T07	Budaya	17,9
	Total	**117,4**

8. Etika

- **Persetujuan.** Semua penutur menandatangani formulir persetujuan (*informed consent*) sebelum direkam, termasuk

persetujuan agar datanya disimpan di repositori GitHub yang bisa diakses publik.

- **Identitas.** Penutur hanya dikenali lewat kode. Nama orang di transkrip diganti dengan `[NAME]`, dan nama asli serta kontak tidak disimpan.
- **Lokasi.** Daerah asal dicatat sampai tingkat kota saja.
- **Lisensi.** Data dilisensikan CC BY-NC 4.0 sehingga hanya boleh dipakai untuk pendidikan dan penelitian nonkomersial.

9. Kendala

- Transkrip S01–S08 masih hasil ASR yang belum dikoreksi penuh sehingga akurasinya terbatas.
- Rekaman S09 memakai *bitrate* yang lebih rendah dari penutur lain sehingga SNR-nya paling rendah, walaupun masih lolos kriteria Good.
- Sesi S01 terlalu panjang sehingga dipotong agar sesuai target durasi.
- Cakupan topik belum merata. Topik keluarga dan perjalanan paling sedikit.
- Segmen dipotong di titik jeda sehingga belum tentu per kalimat, dan batas potongan topik bisa meleset beberapa detik.

10. Kontribusi Anggota

Pembagian kerja anggota kelompok dapat dilihat pada Tabel 9.

Tabel 9. Kontribusi anggota

Nama	**NIM**	**Kontribusi**
Nadhif Radityo Nugroho	13523045	Konversi audio dan *quality control*
Aldoy Fauzan Avanza	18223113	Koordinator kelompok dan pengelolaan

		metadata
M Rabbani K A	18223130	Anotasi dan pengelolaan repositori GitHub