IF4071 Pemrosesan Ucapan

Semester 1 2026/2027

Spesifikasi Tugas Besar Fase 1

Pengumpulan Korpus Suara Bahasa Daerah Indonesia

Lakukan pembuatan korpus suara untuk membangun sistem pengenal ucapan bahasa daerah yang akan dikerjakan pada fase 2 tugas besar pada kuliah ini.

---

1. Ketentuan Kelompok

- Dikerjakan secara berkelompok, 5 mahasiswa/kelompok.
- Setiap kelompok memilih satu bahasa daerah di Indonesia.
- Bahasa yang dipilih harus sesuai dengan kemampuan bahasa anggota kelompok, sehingga anggota kelompok mampu berkomunikasi dengan penutur dan memahami konteks percakapan.

2. Spesifikasi Korpus

Aspek	Ketentuan
Bahasa	1 bahasa daerah/kelompok
Jumlah penutur	10 orang
Gender	5 laki-laki + 5 perempuan
Jenis ucapan	Spontaneous Speech / Conversation
Topik	Minimal 3 topik
Durasi	±10–15 menit/penutur
Sampling rate	16 kHz
Bit depth	16-bit

Aspek	Ketentuan
Channel	Mono
Format	WAV
Lingkungan	Indoor, relatif tenang
Metadata	Wajib
Quality control	Good / Acceptable / Reject
Annotation	Transkripsi dan label sesuai kebutuhan

3. Proses Pengerjaan

Tahap 1 — Define Purpose

Tentukan:

- tujuan pengumpulan korpus
- bahasa/dialek yang dikumpulkan
- jenis ucapan
- karakteristik penutur
- penggunaan korpus

Tahap 2 — Design Corpus

Buat rancangan:

- jumlah penutur
- pembagian laki-laki/perempuan
- jenis dan jumlah topik
- durasi rekaman
- format audio
- metadata
- skema pelabelan

Tahap 3 — Select Speakers

- Pilih 10 penutur dengan komposisi: 5 laki-laki + 5 perempuan
- Catat informasi yang relevan seperti Speaker ID, bahasa/dialek, daerah asal, dan latar belakang penggunaan bahasa.

Tahap 4 — Prepare Recording

Sebelum merekam:

- siapkan microphone/perangkat
- pilih ruangan yang relatif tenang
- atur posisi microphone
- atur recording level
- lakukan test recording
- periksa hasil test

Tahap 5 — Record

Gunakan prompt, bukan dialog yang harus dibaca.

Contoh topik:

1. Perkenalan
2. Aktivitas sehari-hari
3. Keluarga
4. Makanan
5. Pekerjaan/pendidikan
6. Perjalanan
7. Budaya daerah

Gunakan minimal **3** **topik** dan biarkan penutur berbicara secara natural.

---

4. Metadata

Buat satu file **metadata.csv**.

Minimal berisi:

File	Speaker	Gender	Language/Dialect	Topic	Duration	Environment	Quality
S01_T01_001.wav	S01	F	Sunda	Daily	4.2	Indoor	Good
S02_T01_001.wav	S02	M	Sunda	Family	5.1	Indoor	Good

---

5. Quality Control

Periksa setiap rekaman:

- suara terdengar jelas
- tidak terjadi clipping
- noise masih dapat diterima
- tidak ada suara orang lain yang mengganggu
- rekaman tidak terpotong
- format sesuai
- metadata lengkap

Kemudian beri label: **Good | Acceptable | Reject**

Untuk file **Reject**, lakukan *re-recording* jika memungkinkan.

---

6. Annotation / Pelabelan

Minimal lakukan:

☐ **Transkripsi**
☐ **Label speaker**
☐ **Label bahasa/dialek**
☐ **Label topik**
☐ **Label kejadian khusus** seperti noise, overlap, laughter, dll.
☐ Label lain sesuai tujuan korpus

---

7. Review

Setelah pelabelan:

Audio → Annotation → Review → Perbaikan → Final Annotation

Periksa:

- kesesuaian transkripsi dengan audio
- kesesuaian Speaker ID
- kesesuaian label bahasa/dialek
- kesesuaian segmentasi
- konsistensi format label
- kelengkapan metadata

Pelabelan harus diperiksa untuk memastikan akurasi dan konsistensi.

---

8. Struktur Folder

Korpus_Bahasa_[NamaBahasa]/
│
├── audio/
│ ├── S01/
│ ├── S02/
│ ├── ...
│ └── S10/
│
├── metadata/
│ └── metadata.csv
│
├── annotation/
│ └── annotation.csv
│
├── consent/
│ └── consent_form/
│
└── documentation/
└── README.txt

---

9. Pembagian Tugas dalam Kelompok

Setiap kelompok terdiri dari **5 mahasiswa**. Pembagian awal dapat dilakukan sebagai berikut:

Anggota	**Tanggung Jawab**
Mahasiswa 1	Koordinator + 2 penutur
Mahasiswa 2	Recording + 2 penutur
Mahasiswa 3	Recording + 2 penutur
Mahasiswa 4	Metadata + 2 penutur
Mahasiswa 5	QC + Annotation + 2 penutur

Catatan: seluruh anggota tetap bertanggung jawab terhadap keseluruhan kualitas korpus dan sebaiknya saling melakukan **review/QC**.

---

10. Output yang Dikumpulkan

Setiap kelompok mengumpulkan **satu folder korpus** yang berisi:

1. 10 penutur (5 laki-laki + 5 perempuan)
2. File audio WAV
3. metadata.csv
4. annotation.csv
5. Dokumen informed consent
6. Dokumentasi hasil QC
7. README/dokumentasi korpus
8. Laporan singkat proses pengumpulan

Prinsip penilaian

Good Speech Corpus = Purpose + Quality + Diversity + Metadata + Ethics

Jadi, bukan hanya jumlah rekaman yang dinilai, tetapi juga kesesuaian bahasa, keberagaman penutur, kualitas audio, kelengkapan metadata, kualitas anotasi, dan kepatuhan terhadap etika.

Prosedur Pengumpulan Korpus dan Pengumpulan Tugas

1. **Simpan seluruh data korpus di GitHub**
    - Buat repository GitHub untuk kelompok.
    - Pastikan repository **dapat diakses** oleh dosen/asistena/mahasiswa lain.
    - Upload struktur folder, audio, metadata, annotation, dokumentasi, dan file pendukung lainnya sesuai ketentuan tugas.
2. **Cantumkan link GitHub dalam laporan**
    - Link repository GitHub harus dicantumkan secara jelas pada laporan.
    - Pastikan link dapat dibuka dan data dapat diakses sebelum pengumpulan.
3. **Kumpulkan laporan melalui Edunex**
    - Laporan dikumpulkan melalui **Edunex**.

- **Batas pengumpulan: 21 Oktober 2026, pukul 21.00 WIB.**